日本語の本文を含む論文における文境界の推定

坂比賀 悠真
山手大学 情報科学研究科

概要

本稿では，日本語の本文に英語の術語が混ざる論文を対象に，段落と文の切り出しを検討する．既存の手法は空白で語を区切ることを前提としており，日本語の本文では文の境界を見失う．我々は句点と括弧の対応を手掛かりとする単純な規則を提案し，三つのコーパスで評価した．

1　はじめに

学術論文の多くは英語で書かれているが，国内の学会誌には日本語で書かれたものも多い．そうした論文では，術語だけが英語のまま残されることが普通である．たとえば attention や transformer といった語は，訳さずにそのまま使われる．この混在は，空白を手掛かりに語を切る解析器にとって厄介な性質を持つ．英語の部分では空白が語の区切りになるが，日本語の部分では空白がまったく現れない．行の折り返しは語の途中でも起きるため，行を素朴に繋ぐと語が割れてしまう．

本稿の貢献は三つある．第一に，日本語と英語が混ざった本文で文の境界を求める規則を示す．第二に，その規則を三つのコーパスで評価し，既存手法との差を報告する．第三に，残った誤りを分類し，どこに限界があるかを明らかにする．

2　関連研究

文の境界推定は古くから研究されており，英語では終止符と大文字の組み合わせが主な手掛かりである．日本語では句点がほぼ唯一の手掛かりだが，括弧の中の句点を数えてしまう誤りが多い．実装としては `nltk` や `spacy` が広く使われているが，いずれも空白で語が区切られることを前提にしている．近年は学習に基づく手法も提案されているが，分野ごとの学習データが必要になる [1]．本稿が対象とするのは，学習データを用意できない場面である．

3　提案手法

提案手法は，句点の直後で切ることを原則とし，括弧の対応が取れていない位置では切らない．英語の術語が括弧の中に置かれる場合を考慮し，全角と半角の括弧を同じものとして扱う．また，箇条書きの行頭記号は文の始まりとみなし，直前で必ず切る．入力の長さを n とすると，提案手法の計算量は文字数に比例し，追加の記憶領域は定数である．規則はすべて決定的であり，同じ入力に対して必ず同じ出力を返す．

4　実装

提案手法は五百行程度の手続き型の実装であり，外部の辞書も学習済みの模型も使わない．入力は版面から取り出した文字片の列で，出力は文の列である．文字片は座標を持つので，行にまとめる処理を先に通してから文に割る．行にまとめる処理は，段の切れ目を空白の帯として



Figure 1: 提案手法の処理の流れ．行の継ぎ目で空白を入れるかどうかを文字の種類で決める．

検出し，左の段から順に読む．この順序を誤ると，左右の段が一行の中で混ざり，文がすべて壊れる．

行を繋ぐ位置では，継ぎ目の両側の文字を見て空白の要否を決める．両側が和文であれば空白を入れず，両側が欧文であれば空白を入れる．片側だけが和文である場合は，同じ文書の行の途中の書き方に合わせる．この判断は文書ごとに一度だけ行い，以降は同じ判断を使い回す．判断の材料が一つも無い文書では，欧文と同じ扱いにする．

5　評価

三つのコーパスは，情報処理学会論文誌，人工知能学会誌，および arXiv の和文要旨から構成される．いずれも人手で文の境界を付与し，二人の作業者の一致率は九十七パーセントであった．提案手法の F 値は三つのコーパスでそれぞれ九十四，九十二，八十九であった．既存手法との差はいずれのコーパスでも有意であった．誤りの多くは，箇条書きと表の見出しが本文に混ざる場合に集中していた．

処理時間は百ページの論文で一秒未満であり，実用上の問題は無い．記憶領域は文字片の数に比例し，百ページの論文で数十メガバイトに収まる．いずれの指標も既存の実装と同等であり，速度を犠牲にしていない．

6　考察

残った誤りの半分は，見出しが本文として扱われたことに起因する．和文の見出しは番号と本文の間に空白が一つ入るだけで，欧文のような大文字の手掛かりが無い．文字の大きさだけを手掛かりにすると，本文と同じ大きさで組まれた小見出しを取り逃がす．この問題は文の切り出しとは独立であり，行の役割を決める処理の側で解くべきである．

もう一つの誤りは，柱と本文が同じ段に並ぶ場合に起きる．柱は複数のページに同じ字面で現れるので，ページ数が少ない文書では判別が難しい．この場合も文の切り出しではなく，行の役割を決める処理の問題である．

7　誤りの分析

誤りを種類ごとに数えると，見出しに起因するものが最も多く，次に柱に起因するものが続いた．見出しに起因する誤りは，見出しと直後の本文が一枚の札に同居する形で現れる．柱に起因する誤りは，ページの変わり目で本文の途中に柱の文字列が挟まる形で現れる．どちらも読む側からは「原文がそう書いてある」ようにしか見えないため，気付きにくい．気付きにくい誤りは，気付ける誤りよりも害が大きいと我々は考える．

三つ目の種類は，図表の見出しが本文として扱われる誤りである．和文の図表の見出しは「図 1」「表 2」の形をとり，欧文の版面とは接頭辞が異なる．接頭辞の一覧に和文の語を加えれば解けるが，雑誌ごとに表記が揺れるため万全ではない．我々は，接頭辞に頼らず，版面の位置と前後の行との間隔から判断する方法を検討している．

四つ目の種類は，箇条書きの各項目が一つの文として扱われる誤りである．箇条書きの項目は句点で終わらないことが多く，次の項目と繋がってしまう．行頭の記号を手掛かりにすれば

切れるが，記号の種類は版面によって異なる．この種類の誤りは全体の一割に満たないため，優先度は低いと判断した．

8　他の言語への拡張

中国語は日本語と同じく分かち書きをしないので，同じ規則がそのまま使える．一方，朝鮮語は分かち書きをするため，行の継ぎ目には欧文と同じく空白が要る．同じ東アジアの文字であっても，空白の扱いは言語によって異なる．したがって，文字の範囲を「東アジアの文字」とひとまとめにする実装は誤りである．我々の実装は，漢字・ひらがな・カタカナ・全角記号のみを対象とし，ハングルを含めない．

縦書きの版面については，行の向きが変わるだけで規則そのものは変わらない．ただし，版面から行を組み立てる処理は縦書きを想定していないため，別に手当てが要る．振り仮名は本文と重なる位置に置かれるため，行の組み立ての段階で落とす必要がある．これらは今後の課題である．

9　おわりに

日本語と英語が混ざった論文の文境界推定について，学習を必要としない規則を示した．三つのコーパスで既存手法を上回る結果が得られた．今後は，数式が本文に混ざる場合への拡張を検討したい．

References

[1] H. Sato and I. Suzuki. Sentence boundary detection for Japanese documents revisited. Journal of Information Processing, 62(3):512–523, 2021.

[2] A. Tanaka. Structural analysis of scholarly documents. Journal of the Japanese Society for Artificial Intelligence, 34(2):88–97, 2019.