日本語の本文を含む論文における文境界の推定

坂比賀 悠真
山手大学 情報科学研究科

概要

本稿では、日本語の本文に英語の術語が混ざる論文を対象に、段落と文の切り出しを検討する。既存の手法は空白で語を区切ることを前提としており、日本語の本文では文の境界を見失う。我々は句点と括弧の対応を手掛かりとする単純な規則を提案し、三つのコーパスで評価した。

1　はじめに

学術論文の多くは英語で書かれているが、国内の学会誌には日本語で書かれたものも多い。そうした論文では、術語だけが英語のまま残されることが普通である。たとえば attention や transformer といった語は、訳さずにそのまま使われる。この混在は、空白を手掛かりに語を切る解析器にとって厄介な性質を持つ。英語の部分では空白が語の区切りになるが、日本語の部分では空白がまったく現れない。行の折り返しは語の途中でも起きるため、行を素朴に繋ぐと語が割れてしまう。

本稿の貢献は三つある。第一に、日本語と英語が混ざった本文で文の境界を求める規則を示す。第二に、その規則を三つのコーパスで評価し、既存手法との差を報告する。第三に、残った誤りを分類し、どこに限界があるかを明らかにする。

2　関連研究

文の境界推定は古くから研究されており、英語では終止符と大文字の組み合わせが主な手掛かりである。日本語では句点がほぼ唯一の手掛かりだが、括弧の中の句点を数えてしまう誤りが多い。実装としては `nltk` や `spacy` が広く使われているが、いずれも空白で語が区切られることを前提にしている。近年は学習に基づく手法も提案されているが、分野ごとの学習データが必要になる [1]。本稿が対象とするのは、学習データを用意できない場面である。

3　提案手法

提案手法は、句点の直後で切ることを原則とし、括弧の対応が取れていない位置では切らない。英語の術語が括弧の中に置かれる場合を考慮し、全角と半角の括弧を同じものとして扱う。また、箇条書きの行頭記号は文の始まりとみなし、直前で必ず切る。入力の長さを n とすると、提案手法の計算量は文字数に比例し、追加の記憶領域は定数である。規則はすべて決定的であり、同じ入力に対して必ず同じ出力を返す。

4　実装

提案手法は五百行程度の手続き型の実装であり、外部の辞書も学習済みの模型も使わない。入力は版面から取り出した文字片の列で、出力は文の列である。文字片は座標を持つので、行にまとめる処理を先に通してから文に割る。行にまとめる処理は、段の切れ目を空白の帯として



Figure 1: 提案手法の処理の流れ。行の継ぎ目で空白を入れるかどうかを文字の種類で決める。

検出し、左の段から順に読む。この順序を誤ると、左右の段が一行の中で混ざり、文がすべて壊れる。

行を繋ぐ位置では、継ぎ目の両側の文字を見て空白の要否を決める。両側が和文であれば空白を入れず、両側が欧文であれば空白を入れる。片側だけが和文である場合は、同じ文書の行の途中の書き方に合わせる。この判断は文書ごとに一度だけ行い、以降は同じ判断を使い回す。判断の材料が一つも無い文書では、欧文と同じ扱いにする。

5　評価

三つのコーパスは、情報処理学会論文誌、人工知能学会誌、および arXiv の和文要旨から構成される。いずれも人手で文の境界を付与し、二人の作業者の一致率は九十七パーセントであった。提案手法の F 値は三つのコーパスでそれぞれ九十四、九十二、八十九であった。既存手法との差はいずれのコーパスでも有意であった。誤りの多くは、箇条書きと表の見出しが本文に混ざる場合に集中していた。

処理時間は百ページの論文で一秒未満であり、実用上の問題は無い。記憶領域は文字片の数に比例し、百ページの論文で数十メガバイトに収まる。いずれの指標も既存の実装と同等であり、速度を犠牲にしていない。

6　考察

残った誤りの半分は、見出しが本文として扱われたことに起因する。和文の見出しは番号と本文の間に空白が一つ入るだけで、欧文のような大文字の手掛かりが無い。文字の大きさだけを手掛かりにすると、本文と同じ大きさで組まれた小見出しを取り逃がす。この問題は文の切り出しとは独立であり、行の役割を決める処理の側で解くべきである。

もう一つの誤りは、柱と本文が同じ段に並ぶ場合に起きる。柱は複数のページに同じ字面で現れるので、ページ数が少ない文書では判別が難しい。この場合も文の切り出しではなく、行の役割を決める処理の問題である。

7　誤りの分析

誤りを種類ごとに数えると、見出しに起因するものが最も多く、次に柱に起因するものが続いた。見出しに起因する誤りは、見出しと直後の本文が一枚の札に同居する形で現れる。柱に起因する誤りは、ページの変わり目で本文の途中に柱の文字列が挟まる形で現れる。どちらも読む側からは「原文がそう書いてある」ようにしか見えないため、気付きにくい。気付きにくい誤りは、気付ける誤りよりも害が大きいと我々は考える。

三つ目の種類は、図表の見出しが本文として扱われる誤りである。和文の図表の見出しは「図 1」「表 2」の形をとり、欧文の版面とは接頭辞が異なる。接頭辞の一覧に和文の語を加えれば解けるが、雑誌ごとに表記が揺れるため万全ではない。我々は、接頭辞に頼らず、版面の位置と前後の行との間隔から判断する方法を検討している。

四つ目の種類は、箇条書きの各項目が一つの文として扱われる誤りである。箇条書きの項目は句点で終わらないことが多く、次の項目と繋がってしまう。行頭の記号を手掛かりにすれば

切れるが、記号の種類は版面によって異なる。この種類の誤りは全体の一割に満たないため、優先度は低いと判断した。

8　他の言語への拡張

中国語は日本語と同じく分かち書きをしないので、同じ規則がそのまま使える。一方、朝鮮語は分かち書きをするため、行の継ぎ目には欧文と同じく空白が要る。同じ東アジアの文字であっても、空白の扱いは言語によって異なる。したがって、文字の範囲を「東アジアの文字」とひとまとめにする実装は誤りである。我々の実装は、漢字・ひらがな・カタカナ・全角記号のみを対象とし、ハングルを含めない。

縦書きの版面については、行の向きが変わるだけで規則そのものは変わらない。ただし、版面から行を組み立てる処理は縦書きを想定していないため、別に手当てが要る。振り仮名は本文と重なる位置に置かれるため、行の組み立ての段階で落とす必要がある。これらは今後の課題である。

9　おわりに

日本語と英語が混ざった論文の文境界推定について、学習を必要としない規則を示した。三つのコーパスで既存手法を上回る結果が得られた。今後は、数式が本文に混ざる場合への拡張を検討したい。

参考文献

[1] 佐藤 花子, 鈴木 一郎. 日本語文書における文境界推定の再検討. 情報処理学会論文誌, 62(3):512–523, 2021.

[2] 田中 明. 学術文書の構造解析. 人工知能学会誌, 34(2):88–97, 2019.