注意機構の疎な核について

田中 芽衣

1　はじめに

塊(かたまり)の大きさと到達可能な処理速度の間にどのような釣り合いがあるかを、固定の記憶容量の下で測った。 本論文では疎な注意機構の核について論じる。 実験では固定の記憶容量の下で、塊の大きさと到達可能な処理速度の間にどのような釣り合いがあるかを測った。 提案手法は既存の手法に比べて精度を保ったまま遅延を三割ほど削減できることを示す。 以下では、まず前提を述べ、続いて評価の手順を説明し、最後に限界について議論する。

2　提案手法

疎(そ)な行列の積は、密な行列の積に比べて計算量が小さいことが知られている。 本手法の中心となる考え方は、注意の重みが実際には疎であるという観察に基づいている。 これは経験的に確かめられており、多くの実装で同じ傾向が報告されている。 したがって、密な計算をすべて行う必要はない。 塊ごとに代表値を求めてから、上位のものだけを選ぶ手順を取る。 この手順は既存の実装に小さな変更を加えるだけで組み込める。